

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА

СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ (ИУ5)

ОТЧЕТ

по лабораторной работе

по дисі	циплине:	<u>Технологи</u>	и маши	<u>нного</u> с	<u>обучения</u>		
на тему признако		отка пропу табировани			кодирование	категориальны	_ <u>K</u>
признаке	, mach	пиопровин	<u> </u>	<u> </u>		_	
						_	
						_	
						_	
						_	
						_	
						_	
						_	
Студент	<u>ИУ5-62Б</u> (Группа)			(Поді	пись, дата)	А.Д. Карягин (И.О.Фамилия)	
Руководит	гель					<u>Ю.Е</u> <u>Гапаню</u>	
						сь, дата) амилия)	

Лабораторная работа №3

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных

Цель лабораторной работы

Задание

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:

•обработку пропусков в данных;

[®]кодирование категориальных признаков;

Масштабирование данных.

```
In [140]: import numpy as
np import pandas
as pd import
seaborn as sns
import matplotlib.pyplot as plt
%matplotlib
inline
sns.set(style="ticks"
)
```

Загрузка данных

Ссылка на датасет: https://www.kaggle.com/fivethirtyeight/fivethirtyeight-comic-characters-dataset

```
In [192]: data = pd.read_csv('data/marvel-wikia-data.csv', sep=",") data.head()

Out[192]: page_id name urlslug ID ALIGN EYE HAIR
```

0	1 6 7	Spi der- M an (Pe	\/Spider-Man_(Peter_Par ker)	Se IÆRitity Characters	Good	Hazel E E y e	Brown H a
	8	ter Par ker)				8	r
		Captain					
		America		Public	Good	Blue	White

VCaptain_America_(Steven_Rogers) Identity 7139 (Steven Rogers) Characters Eyes Hair Wohve Public rine 2 64786 (Ja Neutral mes "Log an/" Identity Characters Howl ett) Iron Man Odinson) Identity In [142]: #размер набора данных data.shape Out[142]: (16376, 13) In [143]: # типы колонок data.dtypes Out[143]: page_id int64 name object object urlslug object ID object **ALIGN** EYE object **HAIR** object SEX object object **GSM** object **ALIVE APPEARANCES** float64 FIRST APPEARANCE object float64 Year dtype: object In [144]: # проверим есть ли пропущенные значения data.isnull().sum() Out[144]: page_id 0 name 0 urlslug 0 3770 ID **ALIGN** 2812 EYE 9767 **HAIR** 4264 SEX 854 **GSM** 16286

ALIVE

3

APPEARANCES 1096 FIRST APPEARANCE 815 815

Year

dtype: int64

In [146]: $total_count = data.shape[0]$ print('Всего строк: { }'.format(total_count)) Всего строк: 16376

1. Обработка пропусков в данных

Простые стратегии: удаление

```
In [147]:
                data = data.dropna(axis=1, thresh=int(data.shape[0] * 0.49))
In [148]:
                data.isnull().sum()
Out[148]: page_id
                            0
                           0
            name
                           0
            urlslug
                         3770
            ID
                           2812
            ALIGN
                          4264
            HAIR
                          854
            SEX
            ALIVE
            APPEARANCES
                                 1096
            FIRST APPEARANCE
                                   815
                          815
            Year
            dtype: int64
In [149]:
                data[data['ALIVE'].isnull()]
Out[149]:
                                                            ID ALIGN HAIR SEX ALIVE APPEARANCES
                     page_id
                                  name
                                                  urlslug
              16293
                                             VUser:Mj7711 NaN
                     541449
                                 Mj7711
                                                                  NaN
                                                                        NaN
                                                                              NaN
                                                                                     NaN
                                                                                                     NaN
              16329
                     714409
                             Sharjeel786
                                         VUser:Sharjeel786
                                                          NaN
                                                                  NaN
                                                                        NaN
                                                                              NaN
                                                                                     NaN
                                                                                                     NaN
              16347
                     462671
                                           VUser:TORVtest NaN
                               TOR\/test
                                                                  NaN
                                                                        NaN NaN
                                                                                     NaN
                                                                                                     NaN
In [150]:
                # Удаление 3 строк
                data = data.drop(data.index[[16293,16329,16347]])
In [151]:
                data.isnull().sum()
                            0
Out[151]: page_id
                           0
            name
                           0
            urlslug
            ID
                         3767
            ALIGN
                           2809
            HAIR
                          4261
                          851
            SEX
                             0
            ALIVE
            APPEARANCES
                                 1093
            FIRST APPEARANCE
                                   812
            Year
                          812
            dtype: int64
```

"Внедрение значений" - импьютация (imputation)

Обработка пропусков в числовых данных

```
In [152]: #Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета

num_cols = []

for col in data.columns:

# Количество пустых значений

temp_null_count =

data[data[col].isnull()].shape[0] dt =

str(data[col].dtype)

if temp_null_count>0 and (dt='float64' or

dt='int64'): num_cols.append(col)

temp_perc = round((temp_null_count / total_count) * 100.0, 2)

print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_n ull_count, temp_perc))
```

Колонка APPEARANCES. Тип данных float64. Количество пустых значений 1093, 6.67%. Колонка Year. Тип данных float64. Количество пустых значений 812, 4.96%.

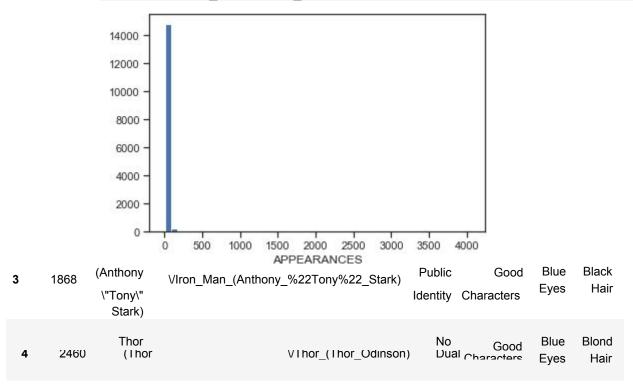
Out[153]:

	APPEARANCES	Year
0	4043.0	1962.0
1	3360.0	1941.0
2	3061.0	1974.0
3	2961.0	1963.0
4	2258.0	1950.0
16371	NaN	NaN
16372	NaN	NaN
16373	NaN	NaN
16374	NaN	NaN
16375	NaN	NaN

16373 rows × 2 columns

s\numpy\lib\histograms.py:840: RuntimeWarning: invalid value encountered in less_equal

keep &= (tmp_a <= last_edge)

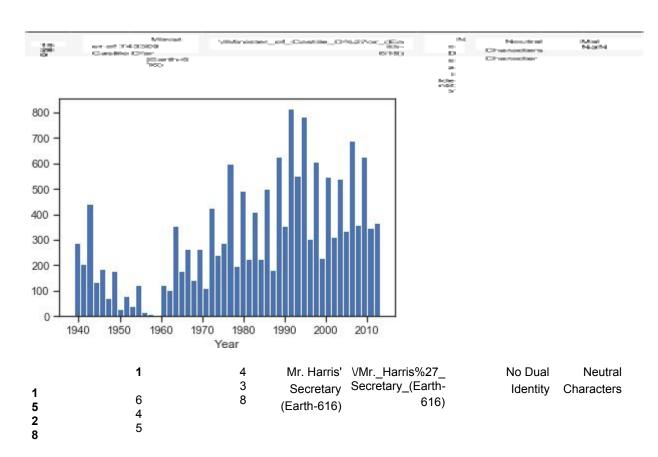


In [155]: #Фильтр по пустым значениям поля APPEARANCES data[data['APPEARANCES'].isnull()]

Out[155]:

page_id name urlslug ID ALIGN HAIR

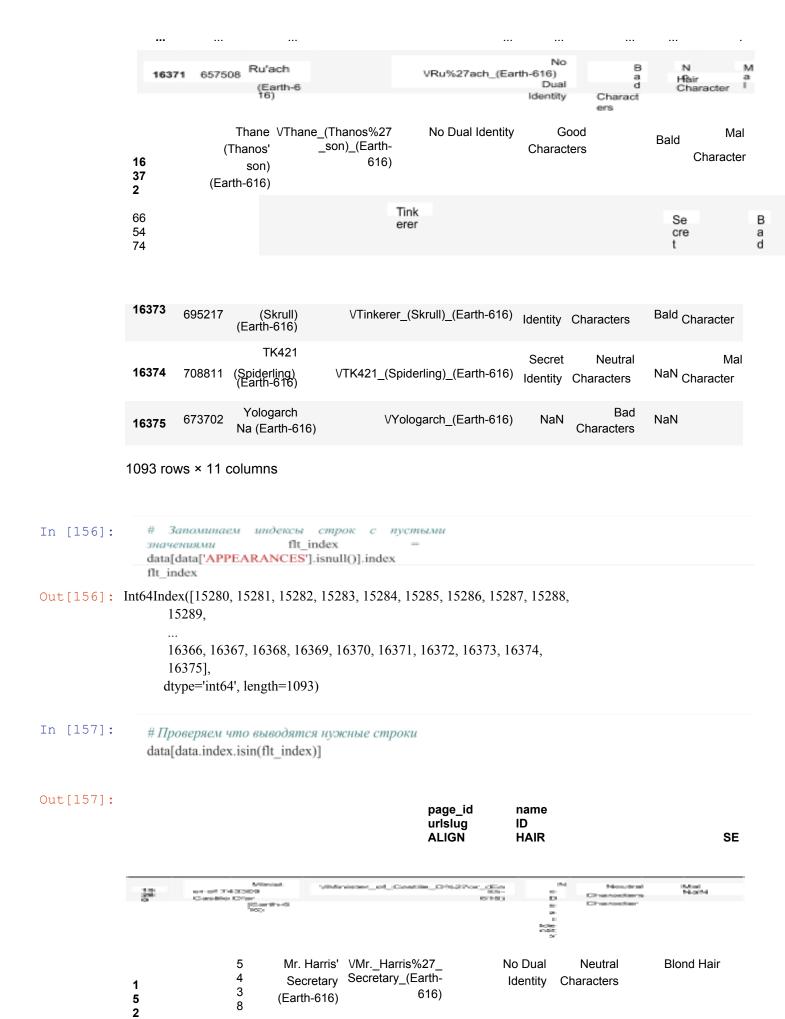
SE



Blond Hair

Femal Character





 Femal Character

15282	331151	N'Jaga (Earth-6		√N%27Ja	aga_(Earth-6	No 16) Dual	B a d	NaN	Mal Chara cter
		(Earth-6 16)				entity C	haract		Cier
15283 50598		VErt _(Ea -616	ırth	od Characters	White Hai	r		Mal Cha	aracter
6		Secr	-et						
Ertve		Iden	tity						
Earth-616)									
		Invis ible				_			
15284 19657		M an (Gade)	VInvisible 16)	e_Man_(Gade)_	(Earth-6	Se Interesters	G o d	NaN	Mal Chara cter
		(Earth- 616)							
						No			





1093 rows × 11 columns

```
In [158]: #фильтр по колонке
data_num[data_num.index.isin(flt_index)]['APPEARANCES']
```

data_num[data_num.index.isin(fit_index)][APPEARANCES

Out[158]: 15280 NaN 15281 NaN

15282 NaN

15283 NaN

15284 NaN

..

16371 NaN

16372 NaN

16373 NaN

16374 NaN

16375 NaN

Name: APPEARANCES, Length: 1093, dtype: float64

In [159]: data_num_APPEARANCES = data_num[['APPEARANCES']] data_num_APPEARANCES.head()

Out[159]: APPEARANCES

0	4043.0
1	3360.0
2	3061.0 2961.0
4	2258.0

```
In [160]:
               from sklearn.impute import SimpleImputer
               from sklearn.impute import MissingIndicator
In [161]:
               # Фильтр для проверки заполнения пустых значений
               indicator = MissingIndicator()
               mask_missing_values_only =
               indicator.fit_transform(data_num_APPEARANCES)
               mask_missing_values_only
```

Out[161]: array([[False],

```
[False],
                 [False],
                 [True],
                 [True],
                 [True]])
In [162]:
                 strategies=['mean', 'median', 'most_frequent']
In [163]:
                 def test num impute(strategy param):
                   imp_num = SimpleImputer(strategy=strategy_param)
                   data_num_imp = imp_num.fit_transform(data_num_APPEARANCES)
                   return data num imp[mask missing values only]
In [164]:
                 strategies[0], test_num_impute(strategies[0])
Out[164]: ('mean',
              array([17.03337696, 17.03337696, 17.03337696, ..., 17.03337696,
                  17.03337696, 17.03337696]))
In [165]:
                 strategies[1], test_num_impute(strategies[1])
Out[165]: ('median', array([3., 3., 3., ..., 3., 3., 3.]))
In [166]:
                 strategies[2], test_num_impute(strategies[2])
Out [166]: ('most_frequent', array([1., 1., 1., ..., 1., 1., 1.]))
             Заменим все пустые данные столбца 'APPEARANCES' на данные
             test_num_impute(strategies[2])
                new_APPEARANCES = pd.DataFrame({'id': flt_index,
In [167]:
                              'APPEARANCES':test_num_impute(strategies[2
                 new_APPEARANCES
Out[167]:
                        id APPEARANCES
                  0 15280
                                        1.0
                    15281
                                        1.0
                 2 15282
                                        1.0
                 3 15283
                                        1.0
                    15284
                                        1.0
              1088 16371
                                        1.0
              1089 16372
                                        1.0
              1090 16373
                                        1.0
              1091 16374
                                        1.0
              1092 16375
                                        1.0
```

1093 rows × 2 columns

In [168]:

for index, row in new_APPEARANCES.iterrows():

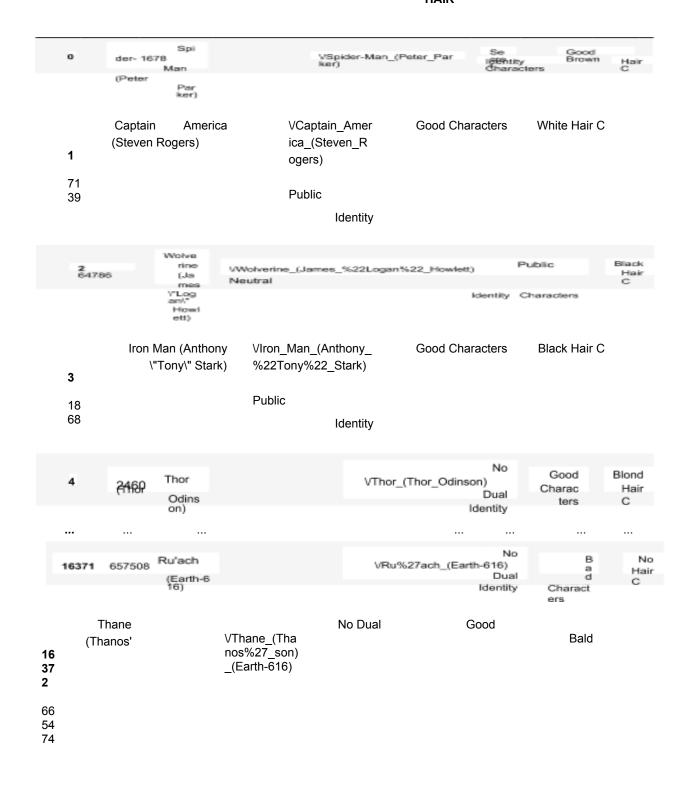
data.loc[row['id'], 'APPEARANCES'] =

row['APPEARANCES']

data

Out[168]:

page_id name urlslug ID ALIGN HAIR





16373 rows × 11 columns

В столбце 'APPEARANCES' больше нет пропущенных данных:

In	[169]	:	data.is	snull().sum()
Out	[169]	:	page_id	0
			name	0
			urlslug	0
			ID	3767
			ALIGN	2809

```
HAIR 4261
SEX 851
ALIVE 0
APPEARANCES 0
FIRST APPEARANCE 812
Year 812
dtype: int64
```

data_imp2

Обработка пропусков в категориальных данных

```
In [170]:
                 #Выберем категориальные колонки с пропущенными значениями
                 # Цикл по колонкам датасета
                 cat cols = []
                 for col in data.columns:
                   # Количество пустых значений
                   temp null count =
                   data[data[col].isnull()].shape[0] dt =
                   str(data[col].dtype)
                   if temp null count>0 and
                     (dt=='object'): cat cols.append(col)
                     temp_perc = round((temp_null_count / total_count) * 100.0, 2)
                     print('Колонка { }. Тип данных { }. Количество пустых значений { }, { } %.'.format(col, dt,
                 temp_n ull_count, temp_perc))
             Колонка ID. Тип данных object. Количество пустых значений 3767, 23.0%.
             Колонка ALIGN. Тип данных object. Количество пустых значений 2809, 17.15%.
             Колонка HAIR. Тип данных object. Количество пустых значений 4261, 26.02%.
             Колонка SEX. Тип данных object. Количество пустых значений 851, 5.2%.
             Колонка FIRST APPEARANCE. Тип данных object. Количество пустых значений 812, 4.96%.
                 cat_temp_data
In [171]:
                 data[['SEX']]
                 cat_temp_data.head()
Out[171]:
                                                                 SEX
                0 Male
                Characters
                 Male Characters
                2 Male Characters
                Male Characters
                4 Male
                Characters
In [172]:
                 cat temp data['SEX'].unique()
Out [172]: array(['Male Characters', 'Female Characters', 'Genderfluid Characters',
                 'Agender Characters', nan], dtype=object)
In [173]:
                 cat_temp_data[cat_temp_data['SEX'].isnull()].shape
Out[173]: (851, 1)
In [174]:
                 # Импьютация наиболее частыми значениями
                 imp2 = SimpleImputer(missing_values=np.nan,
                 strategy='most_frequent') data_imp2 =
                 imp2.fit transform(cat temp data)
```

Out[174]: array([['Male Characters'],

2. Преобразование категориальных признаков в числовые

```
cat_enc =
In [176]:
                 pd.DataFrame({'c1':data_imp2.T[0]})
Out[176]:
                                  с1
                   0 Male Characters
                   1 Male Characters
                   2 Male Characters
                   3 Male Characters
                   4 Male Characters
              16368 Male Characters
              16369 Male Characters
              16370 Male Characters
              16371 Male Characters
              16372 Male Characters
             16373 rows × 1 columns
```

Кодирование категорий целочисленными значениями - label encoding

'Agender Characters'], dtype=object)

3. Масштабирование данных

```
In [184]:
                from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
In [188]:
                sc1 = MinMaxScaler()
                scl_data = scl.fit_transform(data[['Year']])
                plt.hist(data['Year'],
In [189]:
                50) plt.show()
                c:\users\user\appdata\local\programs\python\python37-32\lib\site-packag
                e s\numpy\lib\histograms.py:839: RuntimeWarning: invalid value
                encountered
                 in greater_equal
                  keep = (tmp_a >= first_edge)
                c:\users\user\appdata\local\programs\python\python37-32\lib\site-pack
                age s\numpy\lib\histograms.py:840: RuntimeWarning: invalid value
                encountered
                 in less_equal
                   keep &= (tmp_a <= last_edge)
              800
              700
              600
              500
              400
              300
              200
              100
                0
                                                        2000
                   1940
                         1950
                                1960
                                      1970
                                            1980
                                                  1990
                                                              2010
                     son
                                                                                   Character
                                                     616) Identity Characters
               )
               (Earth-616
               )
                  Tinkere
                                                           Secret
                                                                        Bad
                                                                                        Mal
       695217
16373
                                VTinkerer_(Skrull)_(Earth-616)
                                                                              Bald
                                                                                   Character
                   (Skrull)
                                                          Identity Characters
               (Earth-616)
                   TK421
                                                           Secret
                                                                     Neutral
                                                                                        Mal
16374
       708811
               (Spiderling)
                              VTK421_(Spiderling)_(Earth-616)
                                                                              NaN
                                                          Identity Characters
                                                                                   Character
               (Earth-616)
                     s
                                                                                       С
                                                                    Characters
                                                             Identity
               on)
               (Earth-
               616)
```

16373	695217	Tink er er (S kru II) (Earth-616)	VTinkerer_(Skrull)_(Earth-616) Secre Identity	et Bad Characters	Bald C
16374	708811	TK421 (Spiderling) (Earth-616)	VTK421_(Spiderling)_(Earth-616)	Secret Identity	Neutral Characters	NaN C
In [1	90]:	plt.hist(sc1_data,				

50) plt.show()

